

Projet : Mise en place d'un pipeline de données (ETL)

Parcours : Master Data & IA – M1 – Ynov 2025-2026

Contexte du projet

Les données sont au cœur des projets de Data Science et d'Intelligence Artificielle. Avant toute analyse, visualisation ou modélisation, il est nécessaire de collecter, structurer et préparer les données afin de garantir leur qualité et leur exploitabilité.

Dans ce projet, vous devrez concevoir et mettre en œuvre un pipeline ETL (Extract, Transform, Load) complet permettant de collecter des données issues de différentes sources, de les transformer puis de les intégrer dans une base de données structurée.

Chaque groupe est libre de choisir son sujet d'étude, à condition qu'il implique la collecte et le traitement d'un volume de données suffisant pour justifier la mise en place d'un processus ETL.

Exemples de thématiques possibles

- Sport et performances sportives
- Immobilier
- Transport et mobilité
- Environnement et climat
- Réseaux sociaux
- Santé publique
- Cinéma et plateformes de streaming
- E-commerce
- Tourisme
- Éducation
- Finance et marchés boursiers

Objectif du projet

L'objectif est de construire un pipeline de données robuste permettant de produire un jeu de données propre, cohérent et exploitable.

Vous devrez :

- Identifier des sources de données pertinentes en lien avec votre thématique.
- Concevoir un pipeline ETL complet intégrant les phases d'extraction, de transformation et de chargement.

- Structurer votre projet selon une architecture claire, modulaire et maintenable.
- Mettre en place une base de données relationnelle permettant le stockage et l'exploitation des données.

Architecture recommandée

```
projet_etl/  
├── data/  
│   ├── raw/          # Données brutes collectées (Extract)  
│   └── processed/     # Données nettoyées et transformées (Transform)  
├── scripts/  
│   ├── extract/       # Scripts d'extraction  
│   ├── transform/     # Scripts de nettoyage et transformation  
│   └── load/          # Scripts d'insertion dans la base de données  
├── database/          # Scripts de création de la base et tables  
├── notebooks/         # Analyses exploratoires et tests  
├── requirements/       # Fichiers listant les dépendances du projet  
│   └── requirements.txt # Liste des packages et versions nécessaires  
└── README.md          # Description du projet et instructions
```

Étape 1 – Extraction des données

Vous devez identifier, sélectionner et extraire les données nécessaires à votre sujet.

Les données pourront provenir de différentes sources :

- API publiques
- Fichiers CSV, Excel ou JSON
- Open Data
- Bases de données publiques
- Web scraping
- Réseaux sociaux (si autorisé)
- Jeux de données disponibles sur Kaggle ou plateformes similaires

Tâches à réaliser

- Identifier et documenter les sources de données utilisées.
- Justifier le choix des sources.
- Extraire les données via API, fichiers ou scraping.
- Stocker les données brutes dans le dossier `data/raw/`.
- Décrire le processus d'extraction dans le `README.md`.

Étape 2 – Transformation des données

Vous devez préparer les données afin de les rendre cohérentes et exploitables.

Tâches à réaliser

- Nettoyer les données :
 - suppression des doublons ;
 - gestion des valeurs manquantes ;
 - correction des formats.
- Harmoniser les unités et formats.
- Uniformiser les noms des variables.
- Réaliser les transformations nécessaires à l'analyse.
- Enrichir les données si pertinent.
- Enregistrer les données préparées dans `data/processed/`.
- Conserver les scripts dans `scripts/transform/`.

Étape 3 – Chargement et création de la base de données

Vous devez intégrer les données transformées dans une base de données relationnelle.

Tâches à réaliser

- Concevoir le schéma de la base de données.
- Créer les tables et relations.
- Charger les données nettoyées.
- Vérifier l'intégrité et la cohérence des données.
- Documenter le processus dans le `README.md`.

Livrables attendus

- Code source complet du pipeline ETL.
- Données brutes et données transformées.
- Base de données fonctionnelle.
- Documentation technique (README).
- Présentation finale (07/07/2026)